

Fuzzy Classifier for the Diagnosis of Pathology on the Vertebral Column

J. Contreras, *Member, IEEE*, M. C. Bonfante, A. Quintana and V. Castro

Abstract— This paper describes the training and application of a fuzzy singleton classifier that is used for the diagnosis of pathologies of the vertebral column, discriminating patients as belonging to one out of three categories: Normal, Disk Hernia and Spondylolisthesis. Each input variable is partitioned into triangular membership functions so that consecutive fuzzy sets exhibit a specific overlapping of 0.5. Singleton consequents are employed and least square method is used to adjust the consequents. Applications are conducted on the vertebral column data set from University of California Irvine UCI Machine Learning Repository. Features of the dataset are obtained from sagittal panoramic radiographies of the spine. The dataset includes 310 instances (310 patients) having 6 real valued attributes in 3 classes.

Keywords— fuzzy classifier, diagnosis, vertebral column, disk hernia, spondylolisthesis.

I. INTRODUCCIÓN

Existe un creciente interés de la comunidad científica para el desarrollo de sistemas inteligentes para apoyar al diagnóstico en diferentes campos de la medicina. Una metodología muy empleada es la denominada Aprendizaje de Máquina ML (por su acrónimo en inglés Machine Learning), la cual presenta diferentes técnicas que se apoyan en inteligencia artificial, como las Máquinas de Soporte Vectorial SVM (Support Vector Machine) y las redes neuronales artificiales. Estas técnicas, basadas en inteligencia artificial, han mostrado resultados exitosos en aplicaciones en: cardiología, gastroenterología, oncología, neurología, radiología, citología, genómica, proteómica, entre otros [1].

En la última década ha habido un creciente interés de la comunidad científica en el desarrollo de sistemas inteligentes para el diagnóstico de patologías de la columna vertebral. Las redes neuronales artificiales han mostrado un alto desempeño en aplicaciones de clasificación pero se generan un número elevado de parámetros de ajuste que inciden negativamente en

la complejidad computacional. Una metodología para reducir el número de parámetros consiste en la optimización de los pesos asociados a las neuronas de la capa escondida de un Perceptron multicapa, basada en el análisis de correlación de los errores producidos por las neuronas de salida y los errores retro-propagados asociados con las neuronas escondidas, con lo cual se logra reducir los pesos innecesarios [2]. Esta técnica ha sido empleada con éxito en la clasificación de pacientes que pertenecen a una de las siguientes tres categorías: paciente normal; paciente con hernia discal; paciente con espondilolistesis.

Un programa basado en redes neuronales artificiales fue desarrollado para el diagnóstico de la hernia discal a partir de imágenes de resonancia magnética. El programa implementa un perceptrón multicapa, retropropagación como algoritmo de entrenamiento y la función sigmoide como función de activación. La estructura final consiste de una capa de entrada, una capa escondida y una capa de salida. El error cuadrático medio alcanzado durante el entrenamiento fue cercano a 0.01 y se obtuvo una precisión en el diagnóstico del 95% [3].

Matos y Barreto [4] presentaron 3 estrategias para convertir los algoritmos de entrenamiento no supervisados de Teoría de Resonancia Adaptiva Difusa y Mapas Auto-organizativos en algoritmos de entrenamiento supervisados, generando dos clasificadores: uno de ellos denominado ARTIE (por su acrónimo en inglés Adaptive Resonance Theory networks in Ensembles) y MUSCLE (por su acrónimo en inglés Multiple Self Organizing Map Classifiers in Ensembles), los cuales son aplicados en la base de datos suministrada por UCI Machine Learning Repository para el diagnóstico de patologías de la columna vertebral.

En el año 2012 se presentó una alternativa de red neuronal artificial que presenta una más rápida convergencia y menor carga computacional que el perceptrón multicapa en el proceso de entrenamiento. Esta alternativa utiliza un algoritmo de optimización por enjambre de partícula para entrenar una red neuronal artificial con enlace funcional denominado ISO-FLANN. Esta metodología fue aplicada con relativo éxito en tareas de clasificación y diagnóstico, como el caso de patologías de la columna vertebral [5].

Una alternativa de Máquina de Soporte Vectorial SVM emplea la minimización de las variables de holgura en vez de

J. Contreras, Corporación Universitaria Rafael Núñez y Escuela Naval Almirante Padilla, Cartagena, Colombia, epcontrerasj@ieee.org.

M. C. Bonfante, Corporación Universitaria Rafael Núñez, Cartagena, Colombia, mariaclaudia.bonfante@curn.edu.co.

A. Quintana, Corporación Universitaria Rafael Núñez, Cartagena, Colombia, alvaro.quintana@curnvirtual.edu.co.

V. Castro, Corporación Universitaria Rafael Núñez, Cartagena, Colombia, veronica.castro@curnvirtual.edu.co.

minimizar la norma de los vectores de pesos [6]. Otra alternativa emplea el algoritmo de colonia artificial de abejas como un pre-procesador de los datos con el fin de mejorar la precisión de la Máquinas de Soporte Vectorial SVM [7]. Ambas alternativas son aplicadas a la base de datos suministrada por UCI Machine Learning Repository para el diagnóstico de patologías de la columna vertebral.

La lógica difusa también ha llamado el interés de los investigadores para desarrollar sistemas automáticos de diagnóstico de patologías de la columna vertebral [8], [9].

II. ATRIBUTOS BIOMECÁNICOS DE LA COLUMNA VERTEBRAL

La columna vertebral una compleja estructura compuesta por un grupo de 33 a 34 vértebras distribuidas en 5 regiones: cervical, dorsal, lumbar, sacra y coccígea. Este complejo sistema puede sufrir disfunciones que causan intensos dolores en la espalda. La hernia discal y la espondilolistesis son dos ejemplos de las patologías de la columna vertebral que causan intenso dolor. Estas dos patologías son el resultado de traumas que lesionan progresivamente la estructura del disco intervertebral.

La hernia discal ocurre cuando el disco intervertebral se desplaza hacia la raíz nerviosa, presionándola y generando lesiones neurológicas. La parte baja (región lumbar) de la columna es el área más común para una hernia discal. La espondilolistesis se produce cuando una vértebra se desliza hacia delante, fuera de su lugar normal, sobre la vértebra que se encuentra debajo de ella. Este deslizamiento se produce generalmente hacia la base de la columna vertebral en la región lumbar, causando dolor o irritación de las raíces nerviosas [10].

Para el diagnóstico de patologías de la columna vertebral se consideran seis (6) atributos biomecánicos del sistema espino pélvico por cada paciente:

El ángulo de incidencia pélvica (IP) es el ángulo morfológico que considera la pelvis. Está formado por una línea perpendicular a la plataforma del sacro que inicia en la mitad del mismo hacia distal y una segunda línea que va del centro de las cabezas femorales (CCF) a la mitad de la plataforma del sacro. Este ángulo aumenta durante el desarrollo inicial de la marcha y permanece con un valor medio de 51° durante la vida adulta. La incidencia puede variar de un individuo a otro. Cuando está aumentado, se le asocia a una lordosis lumbar pronunciada, así como a una cifosis torácica y una lordosis cervical superiores a lo normal (tipo dinámico), que corresponde a curvas en la columna de perfil muy acentuadas. Por el contrario, un ángulo menor de lo normal se asocia a curvas en columna vertebral poco pronunciadas (tipo estático).

El ángulo de inclinación de la pelvis (IPE): corresponde a

la inclinación sobre la horizontal de la línea que se extiende entre el promontorio y el borde superior de la sínfisis púbica. Tiene un valor medio de 60°. Cuanto mayor sea el ángulo más nos reflejará una anterversión pélvica o nutación sacra

El ángulo de la lordosis lumbar (LL): El ángulo normal de la lordosis lumbar, varía entre los 35° a 45°, y es medido trazando dos líneas imaginarias que se unen en la parte posterior de la columna, una línea pasa por la cara superior de la vértebra lumbar L5, y la otra pasa por la cara superior de la vértebra sacra S1.

La inclinación del sacro (IS): Este ángulo está formado por una línea tangencial que pasa por el borde posterior del cuerpo de S1 y otra elevada en forma perpendicular a la base de la placa radiográfica. Cuanto mayor es el ángulo, el riesgo de que L5 se deslice sobre S1 es mucho mayor.

El radio de la pelvis (RP): Es la medida de la mitad del llamado eje pelviano, o arco o semicírculo imaginario trazado al interior de la pelvis, cuyo centro está a la mitad de la superficie posterior de la sínfisis púbica. Este radio es justo la mitad de la medida desde el promontorio del sacro a la cara interna de la sínfisis púbica. Las medidas consideradas normales para el diámetro es de 10.5cm (mínimo), lo cual nos quiere decir que el radio es la mitad de esta longitud.

El grado de deslizamiento (GD): Es la medida en la que se desplaza una vértebra sobre la otra. A nivel lumbosacro, se calcula trazando una línea que desciende desde la cara posterior de la vértebra L5 y proyectándose hasta la mitad anterior de la base del Sacro. Esta medida muestra el desplazamiento de la L5 sobre la S1. Si se desliza mucho esta vértebra se genera una espondilolistesis.

III. ALGORITMO DE CLASIFICACIÓN

El clasificador difuso que se genera en el entrenamiento tendrá conjuntos difusos triangulares para la variable de entrada y consecuentes tipo singleton. Para cada conjunto de datos de entrada la salida del modelo difuso estará dada por

$$\begin{bmatrix} y^1 \\ y^2 \\ \vdots \\ y^m \end{bmatrix}_Y = \begin{bmatrix} w_{11}^1 & w_{21}^1 & \dots & w_{nN}^1 \\ w_{11}^2 & w_{21}^2 & \dots & w_{nN}^2 \\ \vdots & \vdots & \ddots & \vdots \\ w_{11}^m & w_{21}^m & \dots & w_{nN}^m \end{bmatrix}_W \begin{bmatrix} \delta_{11} \\ \delta_{21} \\ \vdots \\ \delta_{nN} \end{bmatrix}_\theta \quad (1)$$

Donde w_{mN}^n corresponde al grado de pertenencia del m -ésimo patrón de entrada en el n -ésimo conjunto triangular de la N -ésima variable de entrada. Para el problema tratado en este artículo $N = 6$, y corresponde a los 6 atributos biomecánicos de entrada para lo cual el clasificador difuso

debe emitir un diagnóstico y^m . δ_{nN} corresponde al consecuente asociado al n -ésimo conjunto triangular de la N -ésima variable de entrada. La salida del modelo difuso en cada iteración (aplicación de cada patrón de entrada), estará dada por

$$y(k) = w(k) \cdot \theta(k) \quad (2)$$

ó

$$y^m = w_{11}^m \cdot \delta_{11} + w_{21}^m \cdot \delta_{21} + \dots + w_{nN}^m \cdot \delta_{nN} \quad (3)$$

El vector de consecuentes θ es calculado en cada iteración k empleando mínimos cuadrados recursivos, así:

$$\theta(k) = \theta(k-1) + P(k)W(k)e(k) \quad (4)$$

donde

$$e(k) = y(k) - w(k)\theta(k) \quad (5)$$

$$P(k) = \frac{P(k-1)}{\lambda} \left[I - \frac{w(k)w(k)^T P(k-1)}{\lambda - w(k)^T P(k-1)w(k)} \right] \quad (6)$$

En el inicio, la matriz de covarianzas $P(0)$ se hace igual a la matriz identidad y el factor de olvido λ debe ser un valor mayor de 0 y menor o igual a 1. El vector de consecuentes θ es inicializado por el usuario.

El algoritmo de identificación borrosa a partir de datos experimentales utilizado ha sido explicado ampliamente en [11], [12] y se resume a continuación:

Paso 1: El usuario introduce los datos de las variables de entrada y salida

Paso 2: Se determinan los rangos de cada variable

Paso 3: Se realiza partición uniforme de cada variable de entrada empleando conjuntos difusos triangulares normalizados con solapamiento específico de 0.5 con el fin de asegurar que los soportes de los conjuntos borrosos sean diferentes. La partición de cada variable de entrada queda totalmente definida por un arreglo de valores modales de tal manera que el vértice del lado izquierdo, o derecho, de un conjunto triangular coincide con el valor modal del conjunto vecino ubicado a la izquierda, o derecha, respectivamente, como muestra la Fig. 1. Se inicia con $n = 2$ conjuntos difusos por variable de entrada.

Paso 4: Se determina el vector de consecuentes empleando el método de mínimos cuadrados recursivos

Paso 5: Terminar si se alcanzó una métrica de error menor a una previamente establecida. De no ser así, se incrementa el número de conjuntos difusos n por cada variable de entrada y se va al Paso 3.




Figura 1. Partición difusa con conjuntos triangulares.

IV. RESULTADOS

La base de datos fue creada por el Dr. Henrique da Mota durante su período de residencia médica en el grupo de investigación Group of Applied Research in Orthopaedics (GARO) del Centro de Readaptación Médico Quirúrgica de Massues, Francia. Los datos son organizados en dos archivos con el fin de proponer dos tareas diferentes pero relacionadas. La primera tarea consiste en clasificar pacientes que pertenecen a una de las siguientes categorías: normales (100 pacientes); con hernia discal (60 pacientes) y con espondilolistesis (150 pacientes). La segunda tarea consiste en clasificar los pacientes sanos (100 pacientes) de los pacientes con afección en la columna vertebral (hernia discal y espondilolistesis: 210 pacientes).

La base de datos contiene 7 columnas, de las cuales las 6 primeras corresponden a cada uno de los atributos biomecánicos de la columna vertebral y la columna 7 corresponde al diagnóstico. Los rangos de cada variable, o atributo biomecánico, son:

$$\begin{aligned} IP &= [26.15, 129.8] \\ IPE &= [-6.6, 49.4] \\ LL &= [14.0, 125.7] \\ IS &= [13.37, 121.4] \\ RP &= [70.1, 163.1] \\ GD &= [-11.1, 418.5] \end{aligned}$$

El proceso de entrenamiento se realizó de tal manera que el modelo difuso aproximara a la función discontinua dada por la columna 7. En el Caso ó Tarea I, la columna 7, toma 2 valores: 0 para pacientes normales y 1 para pacientes con hernia discal o espondilolistesis. En el Caso ó Tarea II, la columna 7, toma 3 valores: 0 para pacientes normales; 4 para pacientes con hernia discal; y 8 para pacientes con espondilolistesis. Es decir, el modelo borroso inicialmente generado es más un aproximador que un clasificador.

No se consideran más de 9 conjuntos atendiendo la condición de interpretabilidad que han asumido los investigadores en lógica difusa y que establece que debe definirse un número moderado de etiquetas, ya que los psicólogos establecen 7 ± 2 como un límite en el número de conceptos simultáneos que admite la capacidad de

procesamiento humano [13], [14].

A. Tarea I: clasificación de pacientes en normales y con afección en la columna

La Fig. 2 muestra la partición de la variable de entrada IP (ángulo de incidencia pélvica) con 5 conjuntos triangulares. Las restantes variables de entrada son particionadas de manera similar en sus rangos respectivos.




Figura 2. Partición de la variable de entrada ángulo de incidencia pélvica IP.

Como hay 5 conjuntos por cada una de las 6 variables de entrada, se obtienen 30 consecuentes, así:

$$\theta = \begin{bmatrix} 0.0183 & -0.1381 & -0.1470 & 0.0882 & 0.1810 & -0.0251 \\ 0.1131 & -0.0611 & -0.0802 & 0.0557 & -0.1694 & 0.0372 \\ 0.0967 & 0.0313 & 0.0065 & -0.3912 & 0.1480 & 0.2365 \\ -0.0985 & -0.2146 & -0.2118 & 0.0529 & 0.5002 & -0.1244 \\ 0.5925 & -0.6251 & 0.1334 & 0 & -0.0985 \end{bmatrix}$$

La Fig. 3 muestra la variación del error cuadrático medio a medida que se incrementa el número de conjuntos difusos por variable de entrada.




Figura 3. Variación del error con respecto al número de funciones de pertenencia de las variables de entrada en el proceso de entrenamiento

La Fig. 4 muestra la salida del modelo difuso (línea discontinua) comparada con la función representada por los

datos de la columna 7.




Figura 4. Comparación entre la salida del aproximador difuso (línea discontinua) y el diagnóstico representado por los datos de la columna 7.

Para convertir el aproximador difuso en un sistema de diagnóstico, las salidas menores o iguales a 0.5 se remplazan por 0 (paciente sano) y las salidas mayores a 0.5 se remplazan por 1 (paciente afectado por hernia discal o espondilolistesis). El resultado se puede ver en la Fig. 5, la cual ha sido ampliada, mostrando los resultados de los patrones 100 al 200, para observar mejor los puntos de acierto y desaciertos: el diagnóstico real está representado por el símbolo '*' y el diagnóstico del clasificador difuso está dado por el símbolo 'o'.

La precisión obtenida en el entrenamiento fue de 86.2903% y en la validación de 90.3226%.




Figura 5. Comparación entre la salida del clasificador difuso (o) y el diagnóstico real (*) en el proceso de entrenamiento.

La Fig. 6 muestra el resultado de la validación, considerando el 20% de los datos restantes (62 patrones).




Figura 6. Comparación entre la salida del clasificador difuso (o) y el diagnóstico real (*) en el proceso de validación de la Tarea I.

TABLA I. COMPARACIÓN DE RESULTADOS CON OTROS MÉTODOS.

Método	Máxima Precisión %
Modelo ARTIE [6]	83.87
Modelo MUSCLE [6]	85.81
SVM [7]	89.03
Babalik et al [7]	91.61
Multilayer Perceptron (MLP) [1]	83.03
Generalized Regression Neural Network (GRNN) [1]	83.03
Método propuesto	90.32

Los métodos de clasificación relacionados en la literatura científica, y que son aplicados a la base de datos suministrada por UCI Machine Learning Repository para el diagnóstico de patologías de la columna vertebral, no describen la estructura final del clasificador, lo cual impide realizar una comparación entre los parámetros de ajuste que requiere cada método. La definición de cuántos parámetros se requieren ajustar en un clasificador es indispensable para definir la complejidad de los métodos propuestos y la viabilidad de implementarlos en procesos reales, especialmente cuando se trata de sistemas de clasificación en línea.

B. Tarea II: clasificación de pacientes en normales, con hernia discal y con espondilolistesis

Considerando los mismos 5 conjuntos por cada una de las 6 variables de entrada, como en la tarea anterior, se obtienen 30 consecuentes, así:

$\theta = [0.6909 \quad 1.4097 \quad 2.4405 \quad 0.0517 \quad 0.2433 \quad 1.8081$
 $0.9596 \quad 0.9937 \quad 0.7526 \quad 0.3221 \quad 1.3145 \quad 1.2055$
 $1.1825 \quad 1.1616 \quad -0.0279 \quad 2.4059 \quad 0.6655 \quad 0.3037 \quad -$
 $0.0987 \quad 1.5598 \quad 2.3718 \quad 2.2033 \quad 0.3678 \quad -1.9924$
 $1.8856 \quad -3.6739 \quad 7.0329 \quad -0.0827 \quad 0 \quad 1.5598]$

Para el diagnóstico se considera el valor de 0 para pacientes normales; 4 para pacientes con hernia discal; y 8 para pacientes con espondilolistesis.

La Fig. 7 muestra el resultado de la validación, considerando el 20% de los datos totales (62 patrones), así: 12 patrones para hernia discal; 30 patrones para espondilolistesis y 20 patrones para pacientes en estado normal.




Figura 7. Comparación entre la salida del clasificador difuso (o) y el diagnóstico real (*) en el proceso de validación de la Tarea II.

La precisión obtenida en el entrenamiento fue de 82.258% y en la validación de 85.484%.

V. CONCLUSIONES

Se presenta un método de identificación difusa que genera un clasificador para el diagnóstico automático de patologías de la columna vertebral. El método emplea partición triangular de las variables de entrada y consecuentes tipo singleton y solo requiere del ajuste de los consecuentes, lo cual se realiza empleando el método de mínimos cuadrados recursivo.

La salida del modelo difuso obtenido aproxima al valor asignado previamente que indica el diagnóstico del paciente. Para la tarea I solo existe dos clases: paciente normal, paciente enfermo, mientras que en la tarea II existen tres clases: paciente normal, paciente con hernia discal y paciente con espondilolistesis.

El método requiere muy pocos parámetros de ajustes, solo los consecuentes, y alcanza una alta precisión en comparación con los otros métodos presentados. No se pudo hacer una comparación en cuanto al número de parámetros de ajuste ya que la literatura científica consultada no muestra el número de parámetros requerido por los demás métodos de clasificación de patologías de la columna vertebral.

REFERENCIAS

- [1] Neto, A.R.R., Barreto, G.A. (2009). On the application of ensembles of classifiers to the diagnosis of pathologies of the vertebral column: A comparative analysis. *IEEE Latin America Transactions*, Vol. 7, No. 4, pp. 487-496
- [2] Madeiros, C., Barreto, G.A. (2007). An efficient method for pruning the multilayer perceptron based on the correlation of errors. In *Proceedings of the 17th international conference on Artificial neural networks ICANN 2007*, pp. 219-228. Porto, Portugal.
- [3] Karlik, B., Kul, S. (2009). Diagnosis of Lumbar Disc Hernia Using Wavelet Transform and Neural Network. In *Proceedings of the 2010 International Conference on Image Processing, Computer Vision, & Pattern Recognition, IPCV 2010*, Las Vegas, Nevada, USA.

- [4] Mattos, C.L.C., Barreto, G.A. "ARTIE and MUSCLE models: building ensemble classifiers from fuzzy ART and SOM networks". *Neural Computing & Applications*, Vol. 22, No. 1, pp. 49-61. 2013.
- [5] Dehuri, S., Roy, R., Choc, S.-B., Ghosh, A., "An improved swarm optimized functional link artificial neural network (ISO-FLANN) for classification". *The Journal of Systems and Software*, vol. 85, pp. 1333–1345. 2012.
- [6] Kotti, M., Diamantaras, K.I., "Towards minimizing the energy of slack variables for binary classification", 20th European Signal Processing Conference (EUSIPCO 2012). *Bucharest, Romania*, pp. 644-648. 2012
- [7] Babalik, A., Babaoğlu, I., Özkıs, A., "A Pre-Processing Approach Based on Artificial Bee Colony for Classification by Support Vector Machine", *International Journal of Computer and Communication Engineering*, Vol. 2, No. 1, pp. 68 – 70. 2013.
- [8] Kadhim, M.A., Alam, M.A., Kaur, H., "Design and Implementation of Fuzzy Expert System for Back pain Diagnosis". *International Journal of Innovative Technology & Creative Engineering*. Vol. 1, No. 9, pp. 16 – 22. 2011.
- [9] Qidwai, U., Shamim, S., Enam, A. "Fuzzy prediction for failed back surgery syndrome". *Applied Artificial Intelligence*. Vol. 24, No. 10, pp. 881-895. 2010
- [10] Gamelas, R.J. (2012). *Multicriteria Learning on Ordinal Data*. Universidade do Porto. PhD Thesis
- [11] Contreras, J., Misa, R., Urueta, L. "Algoritmos para Identificación de Sistemas Borrosos Interpretables". *IEEE Latin America Transactions*. Vol. 5, No. 5, pp. 346-351. 2007.
- [12] Contreras, J., Misa, R., Murillo, L. "Obtención de Modelos Borrosos Interpretables de Procesos Dinámicos". *Revista Iberoamericana de Automática e Informática Industrial RIAI*, Vol. 5, No. 3, pp. 70-77. 2008.
- [13] Espinosa, J., Vandewalle, J. "Constructing Fuzzy Models with Linguistic Integrity from Numerical Data-Afrelí Algorithm". *IEEE Transaction on Fuzzy Systems*, Vol. 8, No. 5, pp. 591 – 600. 2000
- [14] Alonso, J.M., Magdalena, L. "Equilibrio entre Interpretabilidad y Precisión en Sistemas Basados en Reglas Difusas: Nuevos retos". *XIV Congreso español sobre tecnologías y lógica fuzzy ESTYLF 2008*. Cuencas Mineras, España, pp. 501-506. 2008.



Juan Contreras, se graduó de Ingeniero Electricista en 1987 en la Universidad Tecnológica de Bolívar y como especialista en Automatización Industrial en 1998 en la misma universidad. En el año 2008 obtuvo el título de PhD en el Instituto Superior Politécnico José Antonio Echeverría, en La Habana, Cuba. Su campo de interés incluye la Identificación

de Sistemas, Control Inteligente y el desarrollo de métodos de modelación y control difusos.



María Claudia Bonfante es Ingeniera de Sistemas, especialista en Auditoria de Sistemas y Candidato a Doctor en Ingeniería de Software de la Universidad Pontificia de Salamanca en Madrid, España. Experiencia en proyectos de investigación relacionados con tecnología informática. Entre sus áreas de interés se encuentran la ingeniería de software, software educativo, ingeniería ontológica y las tecnologías para la gestión de procesos de negocios.



Alvaro Quintana, se graduó de Odontólogo en la Universidad de Cartagena en el año 1998 y de Máster en Dirección Estratégica planificación y control de la Gestión en el IEE España en el 2012. Su campo de interés ha sido la gestión de proyectos e investigación en salud y educación.



Verónica Castro, se graduó de Instrumentadora Quirúrgica en la Corporación Universitaria Rafael Núñez en el año 2006 y cursa Maestría en Salud Pública en la Universidad del Norte, en Barranquilla, Colombia. Su campo de interés ha sido la Neurocirugía